



동결



학습

참조 오디오 · 텍스트

CLAP

512-d · L2 정규화

clap_projection

512 → 1024 → ReLU → 1024

MIDI

MT3 토큰화

노트당 4토큰

토큰 임베딩 — 합산

$\text{midi_tok_embed} + \sum_{i=1}^9 \text{audio_tok_embed}[i] \rightarrow [B, T, 1024]$

타겟 오디오 (학습 시)

DAC 인코더

44.1 kHz · RVQ 코드북 9

시퀀스 조립

$\text{concat}(\text{clap_proj}[B, 1, 1024], \text{tok_emb}[B, T, 1024]) + \text{pos_embed}$

디코더 전용 트랜스포머 × 12

16 head · d 1024 · FFN 4096 · dropout 0.1

인과 마스크 · 175M 파라미터

LayerNorm → fc

Linear(1024, 1133 + 9×1025 = 10358)

자기회귀 샘플링

top-p · First-Note Guidance (y)

DAC 디코더

delay pattern 해제 · 44.1 kHz 파형